

실습 4 · Pandas 2.x 데이터 정제

```
=====
STEP 0. 정제 전 데이터 진단
=====
```

```
데이터 크기 : (5000, 7)
```

```
[컬럼별 타입과 결측치]
```

```
<class 'pandas.DataFrame'>
```

```
RangeIndex: 5000 entries, 0 to 4999
```

```
Data columns (total 7 columns):
```

#	Column	Non-Null Count	Dtype
0	order_id	5000 non-null	str
1	order_date	5000 non-null	str
2	region	4694 non-null	str
3	category	5000 non-null	str
4	quantity	5000 non-null	int64
5	unit_price	4790 non-null	float64
6	discount	5000 non-null	float64

```
dtypes: float64(2), int64(1), str(4)
```

```
memory usage: 429.6 KB
```

```
[컬럼별 결측치 개수]
```

order_id	0
order_date	0
region	306
category	0
quantity	0
unit_price	210
discount	0

```
dtype: int64
```

```
[수치형 기술통계]
```

	quantity	unit_price	discount
count	5000.000000	4790.000000	5000.000000
mean	18.561200	151030.201879	0.049370
std	134.098936	88652.988253	0.057365
min	1.000000	-299111.000000	0.000000
25%	3.000000	77044.000000	0.000000
50%	6.000000	151162.500000	0.000000
75%	8.000000	227002.500000	0.100000
max	1995.000000	299608.000000	0.150000

```
[데이터 앞 5행]
```

	order_id	order_date	region	category	quantity	unit_price	discount
0	ORD-000000	2025-04-07	Busan	Beauty	6	12609.0	0.00
1	ORD-000001	2025-04-08	Busan	Home	1	262252.0	0.05
2	ORD-000002	2025-03-01	Gwangju	Beauty	3	34466.0	0.15
3	ORD-000003	2025-01-11	Seoul	Electronics	3	127645.0	0.00
4	ORD-000004	2025-04-16	Busan	Beauty	3	46037.0	0.00

```
=====
STEP 1. 타입 정규화 후
=====
```

```
order_id          str
order_date        datetime64[us]
region            string
category          category
quantity          int64
unit_price        float64
discount          float64
dtype: object
=====
```

```
STEP 2. 결측치 처리
=====
```

```
unit_price 결측 : 210건 → 0건
unit_price 음수 : 29건 → 0건
region 결측 : 306건 → 0건
=====
```

```
STEP 3. IQR 이상치 처리
=====
```

```
quantity 최댓값 : 1995 → 15
unit_price 최댓값 : 299608 → 299608
=====
```

```
STEP 4. 카테고리별 집계 groupby.agg
=====
```

	건수	평균 단가	중앙 단가	총 매출
category				
Food	1049	150797.8	150472.0	838002283.5
Beauty	1012	156526.9	159479.0	824667442.2
Fashion	967	155762.0	153534.0	811835494.0
Home	977	150478.7	153996.5	805336411.2
Electronics	995	150542.3	143345.0	803187797.2

```

=====
STEP 5. 카테 고 리 x지 역 매 출 pivot_table
=====
region          Busan          Daegu          Gwangju          Incheon          Seoul          미 상
category
Beauty          146827188.0    136293066.0    152864619.0    175404564.0    167508898.0    45769108.0
Electronics     151041213.0    155643225.0    172002215.0    143833881.0    135123520.0    45543743.0
Fashion         158626728.0    165390262.0    160840258.0    147362268.0    124066019.0    55549958.0
Food            141443927.0    163241573.0    160460528.0    153483823.0    164755358.0    54617074.0
Home            149369673.0    154881416.0    146396177.0    148525631.0    150379009.0    55784505.0
=====

STEP 6. 지역 마 스 터 merge
=====
merge 전 후 행 수 : 5000 → 5000
행 수 일 치 : True

[권역 별 총매출]
권역
영 남          1.522758e+09
수 도 권        1.510443e+09
호 남          7.925638e+08
미 상          2.572644e+08
Name: amount, dtype: float64

[merge 결 과 앞 5행]
   order_id  region  권역  amount
0  ORD-000000    Busan  영 남    75654.0
1  ORD-000001    Busan  영 남   249139.4
2  ORD-000002  Gwangju  호 남    87888.3
3  ORD-000003    Seoul  수 도 권   382935.0
4  ORD-000004    Busan  영 남   138111.0
=====

최 종 확 인
=====
결측치 총합 : 0
최종 데이터 크기 : (5000, 8)
최종 데이터 타입 :
order_id          str
order_date        datetime64[us]
region            string
category          category
quantity          int64
unit_price        float64
discount          float64

```

- `sales_raw.csv` 5,000건을 대상으로 타입 정규화, 결측치 처리, IQR 이상치 처리를 수행했습니다. 단가 결측치 210건과 음수 단가 29건은 카테고리별 중앙값으로 대체했으며, 지역 결측치 306건은 임의 지역 배정을 피하기 위해 '미상'으로 구분했습니다. 수량 이상치는 행을 삭제하지 않고 원저라이징하여 최댓값을 1,995개에서 15개로 조정했습니다. 이후 `groupby.agg`, `pivot_table`, `merge`를 이용해 카테고리·지역·권역별 매출을 집계하고, 병합 후 5,000행이 유지되는지 확인했습니다.

확장 과제 — 정제 규칙을 함수로 만들고 테스트 붙이기.

`clean\_price(df)`, `fill\_missing(df)`, `remove\_outliers(df)` 처럼 각 단계를 함수로 분리하면, 다음 달에 새 데이터가 와도 그대로 재사용할 수 있습니다.

```
===== 실습 4 확장 : 데이터 품질 게이트 =====  
원본 데이터 : 5,000행
```

```
[원본 데이터 검사]  
통과 여부 : False / 위반 4건  
- unit_price 결측치 : 210건  
- unit_price 음수 : 29건  
- region 결측치 : 306건  
- quantity IQR 상한 15.5 초과 : 53건
```

```
[정제 후 데이터 검사]  
통과 여부 : True / 위반 0건
```

- 원본 판매 데이터 5,000건을 데이터 품질 게이트로 검사한 결과, 단가 결측치 210건, 음수 단가 29건, 지역 결측치 306건, 수량 이상치 53건 등 총 4개 유형의 문제를 발견했습니다. 동일한 정제 규칙을 자동 적용한 후 다시 검사한 결과 모든 위반 사항이 0건으로 확인되었습니다. 이를 통해 데이터의 문제를 자동 탐지하고 정제 결과까지 검증하는 과정을 구현했습니다.