

실습 5 · Polars · DuckDB 성능 비교

```
(~venv) gxyeon@sunggyeonui-MacBookPro: Python_data_0720_Day1 %  
===== 엔진 성능 비교 =====  
입력 데이터 : 1,000,000행  
질의 : amount > 0 → event_type별 건수 · 매출 합계 · 평균 금액  
  
[집계 결과]  
event_type  cnt      revenue      avg  
0  purchase  60062  1.511797e+10  251706.0  
1   refund  19844   4.963562e+09  250129.0  
  
세 엔진 결과 동일 검증 통과  
  
[엔진별 실행 시간]  
엔진      시간 (ms)      Pandas 대비  
Polars      59          5.9x  
DuckDB     108         3.2x  
Pandas     350         1.0x  
  
실습 5 엔진 성능 비교 완료  
(~venv) gxyeon@sunggyeonui-MacBookPro: Python_data_0720_Day1 %
```

- 100만 행의 이벤트 데이터에서 실제 결제 금액이 있는 `amount > 0` 행만 필터링한 뒤, 이벤트 유형별 건수·매출합계·평균금액을 Pandas·Polars·DuckDB로 동일하게 집계했습니다. 세 엔진의 결과가 일치하는지 검증한 결과 모두 동일했습니다. 실행시간은 Polars 59ms, DuckDB 108ms, Pandas 350ms로 측정됐으며, Polars가 Pandas보다 약 5.9배 빠르게 처리했습니다. Polars Lazy 방식은 실행 계획을 먼저 세우고 필요한 데이터만 읽어 불필요한 연산을 줄인다는 점을 확인했습니다. (Polars < DuckDB < Pandas 순서가 확인)

+ 창의적 과제

실습 5 확장과제: 반복 실행을 이용한 엔진 성능 안정성 비교

[이 확장과제를 만든 이유] 기본 실습 5에서는 Pandas, Polars, DuckDB를 각각 한 번 실행하고 실행시간을 비교했다. 하지만 실행시간은 파일 캐시, 컴퓨터 상태, 백그라운드 프로그램 등의 영향을 받아 실행할 때마다 달라질 수 있다. 따라서 한 번 측정한 결과만으로 엔진의 성능을 판단하는 것은 정확하지 않을 수 있다고 생각했다.

[확장 방법]

1. 기본 실습과 동일하게 amount > 0인 데이터만 사용한다.
2. event_type별 건수, 매출합계, 평균금액을 계산한다.
3. 각 엔진을 3회씩 반복 실행한다.
4. 특정 엔진이 항상 먼저 실행되는 것을 막기 위해 실행 순서를 변경한다.
5. 총 9개 집계 결과가 모두 같은지 검증한다.
6. 평균, 중앙값, 최솟값, 표준편차와 Pandas 대비 속도를 계산한다.
7. 비교 결과를 CSV 파일로 저장한다. [기본 실습과의 차이] 기본 실습은 각 엔진의 실행시간을 한 번 비교하지만, 확장과제는 반복 측정을 통해 속도뿐 아니라 성능의 안정성까지 비교한다.

```
===== 실습 5 확장 : 반복 벤치마크 =====
각 엔진 3회 실행 · 실행 순서 교차 · 결과 일치 검증

[1회 차 ]
Pandas: 324ms
Polars: 45ms
DuckDB: 97ms

[2회 차 ]
DuckDB: 84ms
Pandas: 291ms
Polars: 16ms

[3회 차 ]
Polars: 15ms
DuckDB: 78ms
Pandas: 283ms

[3회 반복 측정 결과 ]
      min    mean  median    std  pandas_speedup
engine
Polars   14.53   25.02   15.72   17.16             18.53
DuckDB   77.65   86.31   84.22    9.88              3.46
Pandas  282.52  299.43  291.29   22.14              1.00

총 9회 집계 결과 동일 검증 통과
결과 저장 : /Users/gayeon/skala_python/Python_data_0720_Day1/Advanced/output/practice5_benchmark.csv

실습 5 확장 과제 완료
```

- 기본 실습에서는 각 데이터 처리 엔진의 실행시간을 한 번만 비교했지만, 실행시간은 파일 캐시와 컴퓨터 상태에 따라 달라질 수 있다고 판단했습니다. 따라서 Pandas, Polars, DuckDB를 각각 3회씩 반복 실행하고, 특정 엔진이 항상 먼저 실행되는 것을 방지하기 위해 회차마다 실행 순서도 변경했습니다. 총 9개의 집계 결과가 모두 동일한지 검증한 뒤 최솟값, 평균, 중앙값, 표준편차와 Pandas 대비 처리속도를 계산했습니다. 이를 통해 단순한 일회성 속도 비교를 넘어 각 엔진의 성능 안정성까지 확인했습니다.