

종합실습 2 · EDA + 통계 + ML 파이프라인

STEP 1. Polars EDA

데이터 크기 : 7,000행 × 10열

컬럼 : ['customer_id', 'gender', 'senior', 'tenure_months', 'monthly_charges', 'total_charges', 'contract', 'payment_method', 'num_services', 'churn']

[결측치 개수]
shape: (1, 10)

customer_id	gender	senior	tenure_months	...	contract	payment_method	num_services	churn
u32	u32	u32	u32		u32	u32	u32	u32
0	0	0	0	...	0	0	0	0

[이탈 여부별 요약]
shape: (2, 5)

churn	고객 수	평균 월 요금	평균 총 요금	평균 가입 개월
i64	u32	f64	f64	f64
0	5315	67.26	2473.41	36.62
1	1685	75.11	2562.0	34.02

[계약 유형별 이탈률]
shape: (3, 3)

contract	고객 수	이탈률
str	u32	f64
Month-to-month	2289	0.372
Two year	2336	0.177
One year	2375	0.176

STEP 2. HTML 보고서 저장 : /Users/gayeon/skala_python/Python_data_0720_Day1/Total2/output/churn_report.html

STEP 3. 결측치 및 인코딩 준비

total_charges 결측치 : 162건

숫자형 처리 : 중앙값 대체 + 표준화

범주형 처리 : 최빈값 대체 + One-Hot Encoding

=====

STEP 4. 월 요금 t-검정

=====

이탈 고객 평균 월 요금 : 75.11

유지 고객 평균 월 요금 : 67.26

t 통계량 : 9.3889

p-value: 1.2262e-20

검정 결과 : 월 요금과 이탈 사이에 유의한 차이가 있음

=====

STEP 5. 계약 유형 카이제곱 검정

=====

churn	0	1
contract		
Month-to-month	1437	852
One year	1956	419
Two year	1922	414

카이제곱 통계량 : 321.7993

p-value: 1.3249e-70

검정 결과 : 계약 유형과 고객 이탈은 연관이 있음

STEP 6. ColumnTransformer 전처리 구성 완료

=====

STEP 7. RandomForest 모델 학습

=====

훈련 데이터 : 5,600건

평가 데이터 : 1,400건

- 월 요금 t-검정 및 계약 유형 카이제곱 검정 t-검정 $p \approx 1.2e-20$, 카이제곱 $p \approx 1.3e-70$ — 둘 다 유의하게 출력됨을 확인

```
# stratify를 사용해 훈련·평가 데이터의 이탈 고객 비율을 유지한다.  
X_train, X_test, y_train, y_test = train_test_split(  
    X, y, test_size=0.2, random_state=42, stratify=y  
)
```

```
model.fit(X_train, y_train)  
prediction = model.predict(X_test)  
probability = model.predict_proba(X_test)[:, 1]
```

- 참고 : (random_state=42 로 고정해둔 모습입니다.)

```

=====
STEP 8. 모델 성능 평가 및 저장
=====
ROC-AUC: 0.6707

[분류 성능]
      precision    recall  f1-score   support

     0       0.837       0.628       0.718       1063
     1       0.344       0.614       0.441        337

 accuracy          0.590
 macro avg          0.621
weighted avg          0.625

모델 저장 : /Users/gayeon/skala_python/Python_data_0720_Day1/Total2/output/churn_model.joblib
보고서 저장 : /Users/gayeon/skala_python/Python_data_0720_Day1/Total2/output/churn_eda_report.html


✅ 종합실습 2 전체 단계 완료

```

- ROC-AUC $\approx$ 0.66 이 출력됨을 확인

고객 이탈 EDA 보고서

분석 데이터: 7,000건



- html 보고서에 나온 그래프입니다.

<전체 코멘트>

telco_churn.csv의 고객 데이터 7,000건을 대상으로 Polars EDA, Plotly 시각화, 통계 검정 및 고객 이탈 예측 모델을 구현했습니다. total_charges 결측치 162건은 머신러닝 파이프라인에서 중앙값으로 처리하고, 범주형 변수는 One-Hot Encoding했습니다. Welch t-검정 결과 월요금과 이탈 간 유의한 차이가 확인됐으며($p=1.2262e-20$), 카이제곱 검정에서도 계약 유형과 이탈 간 연관성이 확인됐습니다($p=1.3249e-70$). ColumnTransformer와 RandomForest를 연결해 모델을 학습한

결과 ROC-AUC 0.6707을 기록했으며, 학습 모델은 joblib 파일로, 시각화 결과는 HTML 보고서로 저장했습니다.